P3.1. Regresión lineal

Nicolás Vila Blanco

nicolas.vila@usc.es

Intelixencia Artificial [G4012328]

3º Grao en Enxeñaría Informática

Escola Técnica Superior de Enxeñaría (ETSE)
Universidade de Santiago de Compostela (USC)









Aprendizaxe supervisada: problema de regresión

Obxectivo fundamental

Aprender a función matemática que mellor represente os datos dispoñibles e sexa quen de predicir valores continuos con precisión ante novos exemplos.

Características clave:

- **Datos tabulares etiquetados:** pares constituídos por variables de entrada (características) versus saída desexada (resposta).
- **Validación sistemática:** división do conxunto de datos en:
  - **Adestramento (training):** para axustar os parámetros do modelo
  - **Test (test):** para avaliar o rendemento real con datos non vistos

Tipoloxía segundo dimensións:

- **MISO (Multiple-Inputs, Single-Output):** múltiples variables preditoras de entrada para estimar unha única variable continua de saída (caso máis habitual).
- **MIMO (Multiple-Inputs, Multiple-Outputs):** predición simultánea de múltiples saídas continuas correlacionadas.

Notación

Símbolo	Significado e interpretación
m	Número total de exemplos de adestramento no dataset
x	Valores de entrada / características (*features*)
y	Valor de saída real / resposta observada (*target*)
(x, y)	Par entrada-saída xenérico
$(x^{(i)}, y^{(i)})$	Par entrada-saída correspondente ao i-ésimo exemplo ($i = 1, \dots, m$)
$h_\theta(x)$	Función hipótese estimada polo noso modelo (predición $\hat{y}$)
δ, $\delta^{(i)}$	Erro residual ($\delta = h_\theta(x) - y$)
θ_j	Parámetro ou peso axustable j-ésimo do modelo ($j = 0, \dots, n$)
θ	Vector de parámetros do modelo $\theta = [\theta_0, \theta_1, \dots, \theta_n]^T$
α	Taxa de aprendizaxe (*learning rate*) do descenso do gradiente
$J(\theta)$	Función de custo

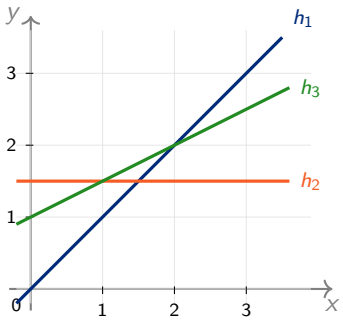
Regresión lineal univariable

Definición da recta de regresión:

$$y = h_\theta(x) = \theta_0 + \theta_1 x$$

Equivalente á clásica ecuación da recta $y = Ax + B$:

- θ_0 (termo B): Valor na orixe (*bias* ou intercepto).
  - Se $x = 0 \implies y = \theta_0$.
- θ_1 (termo A): Pendente da recta.
  - Se $x = 1 \implies y = \theta_0 + \theta_1$.



—	$h_1(x) = x$	$(\theta_0 = 0,\ \theta_1 = 1)$
—	$h_2(x) = 1{,}5$	$(\theta_0 = 1{,}5,\ \theta_1 = 0)$
—	$h_3(x) = 1 + 0{,}5x$	$(\theta_0 = 1,\ \theta_1 = 0{,}5)$

Xeneralización multivariable

Hipótese multivariable (n características de entrada)

Cando temos múltiples variables preditoras $(x_1, x_2, \dots, x_n)$, definimos $x_0 = 1$ para incluír o termo independente:

$$h_\theta(x) = \theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n = \sum_{j=0}^{n} \theta_j x_j$$

Notación matricial:

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix} \in \mathbb{R}^{n+1}, \qquad X = \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{R}^{n+1} \quad (x_0 = 1)$$

$$\mathbf{h}_\theta(\mathbf{x}) = \theta^{\mathbf{T}}\mathbf{X}$$

Como medir o erro do modelo?

Medidas absolutas:

- **Absolute Error (AE):**

$$\mathrm{AE}^{(i)} = |\delta^{(i)}| = \left| h_\theta(x^{(i)}) - y^{(i)} \right|$$

- **Mean Absolute Error (MAE):**

$$\mathrm{MAE} = \frac{1}{m} \sum_{i=1}^{m} |\delta^{(i)}|$$

- Menos sensible a valores atípicos.

Medidas cadráticas:

- **Square Error (SE):**

$$\mathrm{SE}^{(i)} = (\delta^{(i)})^2 = \left(h_\theta(x^{(i)}) - y^{(i)} \right)^2$$

- **Root Mean Square Error (RMSE):**

$$\mathrm{RMSE} = \sqrt{\frac{1}{m} \sum_{i=1}^{m} (\delta^{(i)})^2}$$

- Máis sensible a valores atípicos.

Función de custo: Erro Cadrático Medio (ECM)

Función de custo $J(\theta)$

Para guiar o proceso de aprendizaxe e actualización dos parámetros $\theta = (\theta_0, \theta_1, \dots, \theta_n)$, empregamos a metade do erro cadrático medio:

$$J(\theta_0, \theta_1, \dots, \theta_n) = \frac{1}{2m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right)^2$$

Propiedades matemáticas esenciais:

- **Factor $\frac{1}{2}$:** Inclúese por conveniencia matemática: ao derivar, o factor 2 da potencia cancela co $\frac{1}{2}$.
- **Convexidade:** $J(\theta)$ é unha función estritamente convexa, e polo tanto posúe un único mínimo local, que tamén é mínimo global.
- **Obxectivo de optimización:**

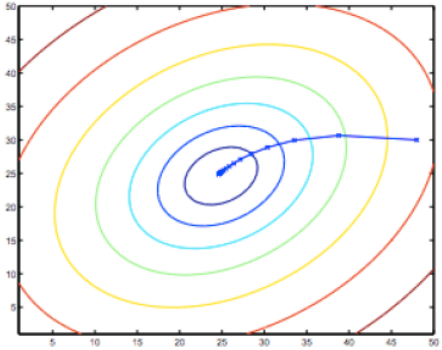
$$\min_{\theta} J(\theta)$$

O algoritmo de descenso do gradiente

Actualización iterativa: partindo dunha estimación inicial (habitualmente $\theta_j = 0$), actualizamos simultaneamente todos os parámetros na dirección oposta ao gradiente:

$$\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$$

- $\alpha > 0$: **taxa de aprendizaxe** (*learning rate*).
  - Se α é *moi pequeno*: converxencia moi lenta.
  - Se α é *moi grande*: pode oscilar ou diverxer.
- $\frac{\partial J}{\partial \theta_j}$: pendente da superficie de custo respecto ao peso θ_j.



Traxectoria cara ao mínimo global nas curvas de nivel de $J(\theta_0, \theta_1)$.

Backpropagation na regresión lineal

gradiente = erro × entrada

Para calcular canto contribúe cada exemplo ao gradiente do peso θ_j, multiplicamos o **erro na saída** ($\delta^{(i)}$) pola **entrada que chega a ese peso** ($x_j^{(i)}$):

$$\text{Contribución do exemplo } \mathbf{i} = \delta^{(\mathbf{i})} \cdot \mathbf{x_j^{(i)}}$$

Termo independente θ_0 ($x_0 = 1$):

$$\text{Gradiente}^{(i)} = \delta^{(i)} \cdot 1 = \delta^{(\mathbf{i})}$$

Entrada sempre 1: o gradiente é directamente o erro $\delta^{(i)}$.

Pendente θ_1 ($x_1 = x$):

$$\text{Gradiente}^{(i)} = \delta^{(\mathbf{i})} \cdot \mathbf{x^{(i)}}$$

Ponderado polo valor da entrada $x^{(i)}$.

Xustificación derivando o custo $J(\theta)$ pola regra da cadea:

$$\frac{\partial J}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^{m} \underbrace{(h_\theta(x^{(i)}) - y^{(i)})}_{\text{erro } \delta^{(i)}} \cdot \underbrace{\frac{\partial h}{\partial \theta_j}}_{\text{entrada } x_j^{(i)}} = \frac{1}{m} \sum_{i=1}^{m} \delta^{(i)} \cdot x_j^{(i)}$$

Regras de actualización dos parámetros

Descenso do gradiente sobre o dataset (m exemplos)

O gradiente global é a **media dos gradientes** individuais de todos os exemplos:

$$\theta_j := \theta_j - \alpha \cdot \frac{1}{m} \sum_{i=1}^{m} \delta^{(i)} x_j^{(i)}$$

Termo independente (θ_0)

$$\theta_0 := \theta_0 - \alpha \cdot \frac{1}{m} \sum_{i=1}^{m} \delta^{(i)}$$

Axústase coa **media do erro**: despraza a recta cara arriba ou abaixo.

Pendente (θ_1)

$$\theta_1 := \theta_1 - \alpha \cdot \frac{1}{m} \sum_{i=1}^{m} \delta^{(i)} x^{(i)}$$

Axústase co **erro ponderado por** x: xira a pendente da recta.

Ambos os dous parámetros actualízanse **simultaneamente** *en cada paso.*

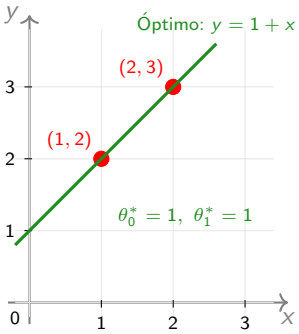
Exemplo paso a paso: datos e configuración

Dataset de xoguete ($m = 2$ exemplos)

- Exemplo 1: $(x^{(1)}, y^{(1)}) = (1, 2)$
- Exemplo 2: $(x^{(2)}, y^{(2)}) = (2, 3)$

Relación ideal subxacente:

$$y = 1 + 1 \cdot x \implies \theta_0^* = 1,\ \theta_1^* = 1$$



Configuración inicial do modelo:

- Hipótese: $h_\theta(x) = \theta_0 + \theta_1 x \quad (x_0 = 1)$
- Inicialización: $\theta_0 = 0,\ \theta_1 = 0$
- Taxa de aprendizaxe: $\alpha = 0{,}1$

Iteración 1 — Paso 1: Forward pass e custo inicial

Paso 1: Forward pass (propagación cara adiante) Calculamos as predicións do modelo para cada exemplo:

$$h_\theta(x^{(1)}) = \theta_0 + \theta_1 x^{(1)} = 0 + 0 \cdot 1 = \mathbf{0}$$
$$h_\theta(x^{(2)}) = \theta_0 + \theta_1 x^{(2)} = 0 + 0 \cdot 2 = \mathbf{0}$$

Paso 2: Cálculo da función de custo inicial $J(\theta)$ Avaliamos o erro cadrático medio cometido coa hipótese actual:

$$J(\theta_0, \theta_1) = \frac{1}{2m}\left[\left(h_\theta(x^{(1)}) - y^{(1)}\right)^2 + \left(h_\theta(x^{(2)}) - y^{(2)}\right)^2\right]$$
$$= \frac{1}{2 \cdot 2}\left[(0-2)^2 + (0-3)^2\right]$$
$$= \frac{1}{4}\left[4 + 9\right] = \frac{13}{4} = \mathbf{3{,}25}$$

Iteración 1 — Paso 2: Backward pass (retropropagación)

1. Erros individuais de predición (δ = predición − real):

$$\delta^{(1)} = h_\theta(x^{(1)}) - y^{(1)} = 0 - 2 = \mathbf{-2}$$
$$\delta^{(2)} = h_\theta(x^{(2)}) - y^{(2)} = 0 - 3 = \mathbf{-3}$$

2. Gradientes medios (Gradiente = media($\delta \cdot$ entrada)):

- **Para o bias θ_0 (entrada $x_0 = 1$):**

$$\frac{\partial J}{\partial \theta_0} = \frac{\delta^{(1)} + \delta^{(2)}}{2} = \frac{(-2) + (-3)}{2} = \frac{-5}{2} = \mathbf{-2{,}5}$$

- **Para a pendente θ_1 (entrada $x_1 = x$):**

$$\frac{\partial J}{\partial \theta_1} = \frac{\delta^{(1)} \cdot x^{(1)} + \delta^{(2)} \cdot x^{(2)}}{2} = \frac{(-2) \cdot 1 + (-3) \cdot 2}{2} = \frac{-8}{2} = \mathbf{-4{,}0}$$

Iteración 1 — Paso 3: Actualización dos pesos

Actualización dos parámetros con $\alpha = 0{,}1$

Aplicamos a regra de descenso do gradiente conxuntamente:

$$\theta_0 := \theta_0 - \alpha \frac{\partial J}{\partial \theta_0} = 0 - (0{,}1) \cdot (-2{,}5) = 0 + 0{,}25 = \mathbf{0{,}25}$$

$$\theta_1 := \theta_1 - \alpha \frac{\partial J}{\partial \theta_1} = 0 - (0{,}1) \cdot (-4{,}0) = 0 + 0{,}40 = \mathbf{0{,}40}$$

Nova ecuación da recta tras unha única iteración de adestramento:

$$h_\theta(x) = \mathbf{0{,}25} + \mathbf{0{,}40}\,\mathbf{x}$$

- Ambos os dous parámetros medraron na dirección correcta (hacia $\theta_0^* = 1$ e $\theta_1^* = 1$).

Iteración 2 — Paso 1: Novo forward pass e redución do custo

Novas predicións tras a actualización dos pesos ($\theta_0 = 0{,}25,\ \theta_1 = 0{,}40$):

$$h_\theta(x^{(1)}) = 0{,}25 + 0{,}40 \cdot 1 = \mathbf{0{,}65} \quad \text{(antes 0, agora máis preto de } y^{(1)} = 2)$$
$$h_\theta(x^{(2)}) = 0{,}25 + 0{,}40 \cdot 2 = \mathbf{1{,}05} \quad \text{(antes 0, agora máis preto de } y^{(2)} = 3)$$

Novo valor da función de custo $J(\theta_0 = 0{,}25, \theta_1 = 0{,}40)$:

$$J(0{,}25, 0{,}40) = \frac{1}{2 \cdot 2}\left[(0{,}65 - 2)^2 + (1{,}05 - 3)^2\right]$$
$$= \frac{1}{4}\left[(-1{,}35)^2 + (-1{,}95)^2\right] = \frac{1{,}8225 + 3{,}8025}{4} = \mathbf{1{,}4063}$$

Redución comprobada do custo (iteración 1)

O custo baixou de $\mathbf{3{,}2500} \rightarrow \mathbf{1{,}4063}$ (**redución do 56.7 %** nunha soa iteración).

Iteración 2 — Paso 2: backward pass e nova actualización

1. Novos erros a partir das predicións (δ = predición − real):

$$\delta^{(1)} = 0{,}65 - 2 = \mathbf{-1{,}35}$$
$$\delta^{(2)} = 1{,}05 - 3 = \mathbf{-1{,}95}$$

2. Novos gradientes medios:

- **Para θ_0:** $\dfrac{\partial J}{\partial \theta_0} = \dfrac{(-1{,}35) + (-1{,}95)}{2} = \dfrac{-3{,}30}{2} = \mathbf{-1{,}65}$
- **Para θ_1:** $\dfrac{\partial J}{\partial \theta_1} = \dfrac{(-1{,}35)\cdot 1 + (-1{,}95)\cdot 2}{2} = \dfrac{-5{,}25}{2} = \mathbf{-2{,}625}$

Iteración 2 — Paso 3: actualización dos pesos

Actualización dos parámetros con $\alpha = 0{,}1$

$$\theta_0 := 0{,}25 - (0{,}1) \cdot (-1{,}65) = 0{,}25 + 0{,}165 = \mathbf{0{,}415}$$

$$\theta_1 := 0{,}40 - (0{,}1) \cdot (-2{,}625) = 0{,}40 + 0{,}2625 = \mathbf{0{,}6625}$$

Nova ecuación da recta tras a segunda iteración de adestramento:

$$h_\theta(x) = \mathbf{0{,}415} + \mathbf{0{,}6625}\,\mathbf{x}$$

- Ambos os dous parámetros continúan achegándose aos valores óptimos ($\theta_0^* = 1$, $\theta_1^* = 1$).

Verificación e táboa comparativa

Predicións e novo custo tras a iteración 2:

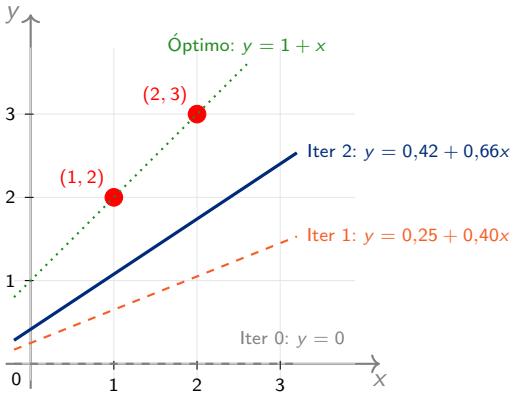
- Exemplo 1: $h_\theta(x^{(1)}) = 0{,}415 + 0{,}6625 \cdot 1 = \mathbf{1{,}0775}$ (*antes* 0,65, máis preto de $y^{(1)} = 2$)
- Exemplo 2: $h_\theta(x^{(2)}) = 0{,}415 + 0{,}6625 \cdot 2 = \mathbf{1{,}7400}$ (*antes* 1,05, máis preto de $y^{(2)} = 3$)
- Custo: $J(0{,}415, 0{,}6625) = \dfrac{(1{,}0775-2)^2 + (1{,}74-3)^2}{4} = \dfrac{0{,}8510 + 1{,}5876}{4} = \mathbf{0{,}6097}$

Evolución paso a paso do modelo:

Iteración	θ_0	θ_1	$h_\theta(1)$	$h_\theta(2)$	**Custo** $J(\theta)$
Iter 0 (inicio)	0.000	0.000	0.00	0.00	3.2500
Iter 1	0.250	0.400	0.65	1.05	1.4063 (−56,7 %)
Iter 2	0.415	0.663	1.08	1.74	**0.6097** (−81,2 %)
Óptimo	*1.000*	*1.000*	*2.00*	*3.00*	*0.0000* (−100 %)

En só dúas iteracións reduciuse máis do 81 % do custo inicial!

Evolución gráfica do exemplo

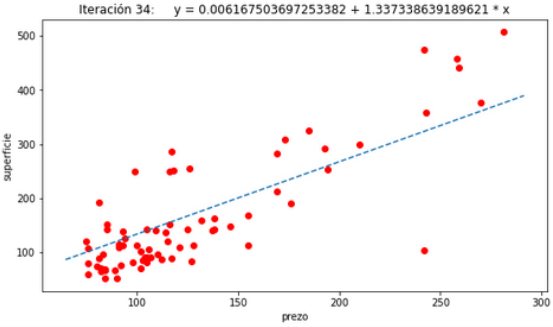


A cada ciclo de retropropagación, a recta vaise axustando progresivamente aos datos de adestramento.

Caso de estudo 1: estimación do prezo de vivendas

Descrición do problema:

- Dataset: `vivendas.csv` (73 exemplos).
- Variable de entrada (x): superficie (m^2).
- Variable de saída (y): prezo (miles de euros).
- Alta correlación lineal positiva ($r > 0$).
- O descenso do gradiente axusta a recta minimizando os residuos.



Recta obtida na iteración 34: $y = 0{,}006 + 1{,}337 \cdot x$.

Impacto dos valores atípicos (*outliers*)

Que é un valor atípico?

- Instancias que se afastan notablemente da distribución xeral dos datos.
- No dataset de vivendas aprécianse inmobles con prezos desproporcionados á súa superficie.
- Como a función de custo $J(\theta)$ emprega o **erro cadrático**, os outliers poden inclinar artificialmente a recta e producir modelos non confiables.
- Detección visual mediante diagramas de caixa (*boxplots*).

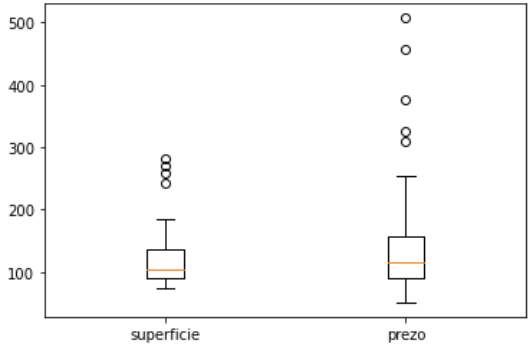
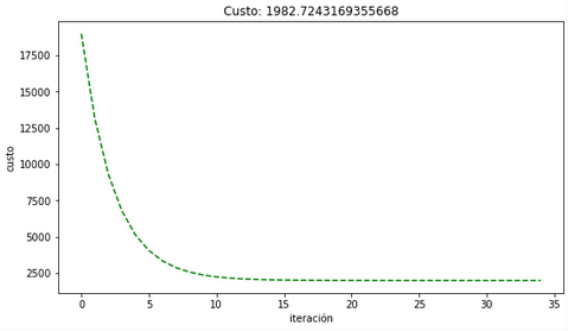


Diagrama de caixas que amosa os outliers en superficie e prezo.

Curva de custo: converxencia do descenso do gradiente

Diagnóstico da aprendizaxe:

- Gráfica de $J(\theta)$ fronte ao número de iteracións.
- Se o algoritmo funciona adecuadamente, a curva de custo **debe diminuír de xeito monótono** en cada iteración.
- Permite determinar o momento no que a aprendizaxe se estabiliza e non paga a pena seguir iterando.



Descenso monótono da función de custo $J(\theta)$ nas 35 iteracións.

Caso de estudo 2: o problema dos cereais (Kaggle)

Dataset: 80 Cereals (Kaggle)

- Múltiples variables preditoras nutricionais:
  - `calories`, `protein`, `fat`, `sodium`, `fiber`, `carbo`, `sugars`, `potass`, `vitamins`, etc.
- Variable obxectivo continua (y): `rating` (puntuación de calidade).

Reto da práctica

Construír un modelo de regresión lineal multivariable con **2 entradas** seleccionadas segundo a súa correlación coa saída, para predicir da mellor forma posible o `rating`:

$$h_\theta(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2$$

Metodoloxía

1. Cálculo da matriz de correlacións **R**.
2. Selección das 2 variables con maior correlación (positiva ou negativa) co `rating`.
3. Axuste con `LinearRegression` de Scikit-Learn.
4. Avaliación con conxunto de test independente.

Referencias bibliográficas

- **Stuart Russell e Peter Norvig**, *"Artificial Intelligence: A Modern Approach"*, 4th Edition.
  - Web oficial: `https://aima.cs.berkeley.edu/`
  - Repositorio de código: `https://github.com/aimacode/aima-python`
- **Kaggle Dataset: 80 Cereals**, Chris Crawford:
  - `https://www.kaggle.com/datasets/crawford/80-cereals`
- **Senén Barro Ameneiro**, *"Aprendizaxe automática / Fundamentos e Regresión Lineal"*, Material docente da materia Intelixencia Artificial, Grao en Enxeñaría Informática, Universidade de Santiago de Compostela.

P3.1. Regresión lineal

Nicolás Vila Blanco

nicolas.vila@usc.es

Intelixencia Artificial [G4012328]

3º Grao en Enxeñaría Informática

Escola Técnica Superior de Enxeñaría (ETSE)
Universidade de Santiago de Compostela (USC)







